

华中科技大学

硕士生论文开题报告

题目:

面向成本优化的长期记忆写入阶段模型路由研究

学号	[待填写]
姓名	[待填写]
专业	[待填写]
指导教师	[待填写]
院（系、所）	计算机科学与技术学院

华中科技大学研究生院制

1 课题背景、目的和意义

1.1 课题背景与问题提出

大语言模型智能体正在由单轮问答扩展到跨会话、长周期的持续交互。受上下文窗口、推理费用和历史信息冗余的共同制约，仅在每次请求中重新拼接全部历史并不能稳定支撑长期记忆。外部持久记忆因此成为常见技术路径：系统先从对话历史中抽取可复用的事实、事件、偏好和约束，再将其写入记忆库，后续查询通过检索相关事实完成回答。MemGPT 以分层记忆和虚拟上下文管理扩展可用上下文[14]，MemoryBank 引入长期记忆更新与遗忘机制[15]，Mem0 和 A-MEM 进一步探索结构化抽取、关联组织和动态演化[9-10]。这些工作说明，记忆写入不是简单存储原文，而是决定长期信息质量和后续问答上限的关键环节。

现有系统通常让同一抽取模型处理全部历史片段。然而，不同片段的抽取难度并不一致。人物属性、显式偏好和直接约束往往只需完成局部识别与规范化；跨句指代、时间关系、事实更新、冲突消解及多实体绑定则需要更强的理解和推理能力。当统一使用高容量模型时，简单片段可能出现“容量过配”：调用成本明显增加，而可用记忆质量未必同步提高。反之，统一使用低成本模型又可能损害复杂片段的事实完整性和忠实度。因此，本课题把研究对象限定为长期记忆写入阶段的片段级模型选择，而不是一般问答阶段的模型路由。

持久记忆还具有一次写入、多次复用的成本结构。设同一段历史在其生命周期内被查询 Q 次，持久写入路线的总成本可表示为写入成本与 Q 次检索、回答成本之和；查询时临时构建路线则需要每次访问时重复承担筛选、抽取或总结开销。两种路线各有适用条件：查询感知方法可以针对当前问题保留证据，离线持久写入更适合稳定事实和重复访问。本课题不预设其中一方在所有场景中占优，而是重点研究在持久写入路线内部，如何依据片段难度选择与之匹配的模型容量，并分析重复查询次数变化时的生命周期质量—成本表现。

1.2 研究目的

本课题拟建立一种面向持久记忆写入的片段级模型路由方法。该方法以主题片段为决策单元，将片段文本表示、结构特征与候选模型的任务相关记忆能力表示结合，预测各候选模型在特定片段上的事实抽取质量；随后将质量预测与外部

价格表、预计 Token 用量及总写入预算解耦，在硬预算约束下完成模型分配。研究希望回答：低难度片段能否由较低成本模型可靠处理，复杂片段是否需要更高能力模型，以及这种差异化分配能否在保持下游记忆效用的同时降低写入成本。

1.3 研究意义

理论上，本课题把通用 LLM 路由中的“请求—模型匹配”推进到“历史片段—记忆抽取模型匹配”，补充长期记忆系统中关于模型容量配置的研究视角。方法上，拟构建价格无关的模型记忆能力表示，并将局部质量预测与外部预算优化分离，使价格或候选模型池变化时可以重新求解分配，而不必把商业价格固化进质量模型。工程上，研究可为长对话助手、个人智能体和持续交互系统提供可审计的写入成本控制机制，并通过 Token、调用、重试和失败记录支持复现。需要强调的是，容量增加是否具有边际收益递减、路由能否接近统一大模型质量，均属于待验证假设，不在开题阶段作为既有结论。

2 国内外研究现状

2.1 长期记忆的表达、写入与维护

长期记忆研究已从“保存全部历史”转向对信息进行选择、组织和更新。MemGPT 借鉴操作系统的分层存储思想，在有限上下文中调度不同记忆层[14]；MemoryBank 通过总结、更新和遗忘支持持续交互[15]。Mem0 从生产系统视角构建可扩展的记忆抽取、整合与检索流程[9]，A-MEM 则使用结构化笔记、动态索引和关联链接组织记忆[10]。Memory-R1 进一步将 ADD、UPDATE、DELETE 和 NOOP 等记忆操作纳入强化学习框架[11]。这条研究线表明，记忆的表达形式、写入粒度和维护策略会共同影响事实可用性。

上述工作主要关注记忆应写入什么、如何组织以及怎样更新。它们为本课题提供了事实抽取、持久化和下游利用的系统基础，但通常不把“为每个主题片段选择不同容量的抽取模型”作为核心决策变量。本课题拟在既有记忆管线中增加模型能力适配层，不替代已有的记忆表示和维护机制。

2.2 记忆系统的效率优化

效率研究主要从减少输入冗余、降低调用次数和差异化维护等方向展开。

LLMLingua-2 把提示压缩建模为任务无关的 Token 分类, 以较小编码器保留关键信息[16]。LightMem 通过轻量预压缩、主题分组、短期记忆整合和离线长期更新降低记忆管线开销[1]。SimpleMem 强调语义压缩、在线语义合成和意图感知检索[12], LeanMem 则依据可压缩性、时间动态和证据保真要求区分不同记忆类型并选择性维护[13]。

这类方法说明, 压缩、分组、异步处理和异质记忆维护可以显著改变系统效率。不过, 减少进入管线的信息量或减少调用次数, 并不等同于解决抽取模型容量过配。即使历史已完成主题分段和压缩, 不同片段对指代解析、时间推理与冲突处理的要求仍可能不同。因此, 模型容量路由与输入压缩并非替代关系, 而是可组合的两个优化层次。

2.3 LLM 路由与质量—成本权衡

通用 LLM 路由研究已经形成较完整的质量—成本权衡框架。FrugalGPT 利用模型级联选择不同服务以降低推理费用[7]; Hybrid LLM 依据输入难度和目标质量在小模型与大模型之间分配请求[8]。RouterBench 提供多模型路由评测数据和统一比较框架[6], RouteLLM 利用偏好数据学习强弱模型路由[4]。UniRoute 通过模型特征表示研究新模型加入后的动态路由[5], LLMRouter 则从上下文编码、模型编码、评分函数、决策规则和学习信号等组件统一描述路由系统[3]。

这些研究主要决定“哪个模型回答当前请求”, 其监督信号通常来自回答质量或偏好。长期记忆写入路由面对的是另一种决策: 哪个模型把某段历史转换为可持久化、可检索的事实。两者在输入、输出、监督信号和成本生命周期上均存在差异。BudgetMem 与本课题更为接近, 它在问题到达后, 对筛选、实体/时间/主题抽取和总结等运行时记忆模块选择低、中、高预算档位[2]。其优势是问题感知, 可以避免离线压缩遗漏当前问题所需信息; 本课题则在问题未知的写入阶段, 为每个主题片段选择记忆抽取模型, 并通过一次写入支持多次检索。二者应被理解为不同决策时机下的互补路线。

2.4 长期记忆评测与当前研究不足

LoCoMo 以多会话长对话评测问答、事件总结和多模态生成[17]; LongMemEval 覆盖信息抽取、跨会话推理、时间推理、知识更新和拒答等长期记

忆能力[18]。HaluMem 把记忆幻觉细分到抽取、更新和问答操作层级[19]，MemoryAgentBench 通过增量多轮交互考察检索、测试时学习、长程理解和选择性遗忘[20]。这些基准为局部事实质量和下游问答效用提供了互补测量依据。

综合来看，现有研究分别从记忆表示、压缩与维护、查询时预算控制以及通用模型路由等方面提升效率，但仍缺少一种面向持久记忆写入阶段的模型容量路由方法。该方法需要以历史主题片段为决策单元，在不使用未来测试问题的前提下预测不同候选模型的事实抽取质量，并在总写入预算约束下完成联合分配。同时，现有长期记忆数据集通常提供问题答案或局部证据，而非覆盖每个主题片段的完整 Gold Fact，这也构成监督标签设计和公平评价的现实难点。

3 研究目标与研究内容

3.1 总体目标与研究问题

总体目标是建立一套可复现、可审计的长期记忆写入模型路由框架，使不同难度的历史片段使用与其需求相匹配的候选模型，在可控预算下兼顾事实抽取质量、下游问答效果和生命周期成本。围绕该目标，设置以下研究问题：

1. RQ1（片段—模型质量预测）：给定历史主题片段和候选模型的任务相关能力表示，能否预测该模型对该片段记忆事实抽取质量？
2. RQ2（预算约束模型分配）：在总写入预算约束下，片段级模型选择能否在接近统一高能力模型记忆质量的同时减少 Token 和费用？
3. RQ3（泛化与生命周期效益）：当候选模型、模型家族、价格表、数据集或重复查询次数发生变化时，方法能否保持稳定的质量—成本表现？

3.2 主要研究内容

第一，研究长对话的主题片段构造与难度表示。在不跨样本混合信息的前提下，将多会话历史划分为语义相对连续的片段，并从冻结文本嵌入和少量可解释结构特征两方面描述片段。结构特征只刻画输入本身，例如长度、轮次数、说话人数量、时间和数字线索、否定与更新线索，不使用测试问题、答案或证据标签。

第二，构建候选模型的价格无关记忆能力表示。拟利用与下游测试集隔离的记忆能力探针，从事实覆盖、目标事实精确性、事实忠实度、状态更新、目标绑

定、旧值拒绝和证据定位等维度形成 **MemoryPrint**。该表示描述模型在记忆任务上的相对能力，不包含参数规模、商业价格或供应商榜单分数。

第三，建立共享的片段—模型质量预测器。对每个片段与候选模型组合，融合片段表示和模型能力表示，输出单一标量质量分数。监督标签拟由冻结参考抽取器、固定评估器和严格事实匹配过程构造的 **Silver Fact** 质量形成，并通过训练集内的交叉验证和隔离审计控制噪声与泄漏。

第四，研究外部成本建模与预算约束分配。根据真实输入、输出 **Token** 和价格快照计算片段—模型成本，将重试、格式修复及产生用量的失败调用纳入审计。在给定总写入预算下，采用确定性约束优化方法为全部片段联合选择模型。价格变化时只更新外部成本表并重新求解，不重新训练质量预测器。

第五，构建持久记忆并评价下游效用。被选模型抽取结构化事实后写入隔离的向量记忆库，使用固定的检索器、回答模型和评估器完成问答。评价同时覆盖局部 **Fact** 质量、下游 **QA**、路由决策、**Token** 与费用，并考察同一历史被多次查询时的累计成本。

3.3 拟解决的关键问题与创新点

拟解决的关键问题包括：片段难度与模型任务能力如何对齐；缺少完整片段级 **Gold Fact** 时如何形成可靠监督；质量预测与价格如何解耦；硬预算下如何联合分配；如何防止问题级信息泄漏；以及怎样公平比较写入时持久记忆与查询时临时记忆。

本课题的创新性以“拟”表述。其一，拟研究无需当前查询、面向持久记忆写入的片段级抽取模型路由。其二，拟将价格无关的 **MemoryPrint** 用于片段—模型质量预测，使候选模型能力而非参数规模进入预测。其三，拟把质量学习与价格、**Token** 及预算决策解耦，以适应价格表和候选池变化。其四，拟建立一次写入、多次复用的生命周期评价方法。上述创新能否成立，需要通过受控实验和消融分析验证。

4 研究方案与可行性分析

4.1 总体研究方案与技术路线

研究采用“输入表征—能力条件化质量预测—外部预算优化—持久写入—效用评价”的技术路线。长对话首先按样本和会话边界完成标准化与主题分段；随后为片段生成冻结文本嵌入及结构特征，并为候选模型生成与下游数据隔离的 MemoryPrint。共享质量预测器对每个片段—模型组合给出质量估计，预算优化器结合价格快照和预计 Token 成本，在总写入预算内选择模型。抽取结果写入持久记忆库，最终通过固定检索、回答和评估协议完成局部事实质量、下游 QA 与生命周期成本分析。

对主题片段 x_i 和候选模型 m ，质量预测记为：

$$\hat{q}(i,m) = f\theta([x_i; c_m])$$

其中， x_i 为片段文本与结构表示， c_m 为候选模型的价格无关能力向量， $\hat{q}(i,m)$ 为预计事实抽取质量。片段—模型调用成本由输入、输出 Token 及外部价格表计算。在总写入预算 B_{write} 下，优化器选择每个片段的模型，使预计总质量最大，同时满足总成本不超过预算。开题阶段只确定变量、约束和验证原则；具体候选模型版本、训练超参数、调用上限和价格快照将在正式实验前冻结并形成配置清单。

面向成本优化的长期记忆写入模型路由




图 1 面向成本优化的长期记忆写入模型路由技术路线

4.2 实验验证方案

数据方面，拟以 LoCoMo 作为主要训练与交叉验证数据，以 LongMemEval

作为冻结外部测试或跨数据集验证，并使用与二者隔离的 HaluMem 或其他能力探针构建 MemoryPrint。所有划分按 conversation 或 sample 进行，测试问题、答案、证据和评估结果不得进入路由训练或超参数选择。候选模型覆盖至少两个模型家族和不同能力档位，但不把参数规模直接视为记忆能力。

对比实验分为两个层次。路由算法层比较统一小、中、大模型、预算匹配随机、长度或复杂度启发式、固定模型池监督路由、强化学习路由、通用路由风格方法及预算 Oracle；端到端系统层根据复现条件比较 Full Context、RAG、代表性长期记忆系统与本课题方法。两类结果分开报告，避免把路由器与完整记忆系统直接混合排名。

评价指标按“质量、路由、成本、生命周期”四组组织。质量指标包括下游 QA 和 Fact Precision、Recall、F1 及忠实度；路由指标包括选择准确性、排序相关性和相对 Oracle 的 regret；成本指标包括输入、输出和总 Token、真实费用、调用次数、延迟及预算违反率；生命周期指标考察不同重复查询次数下的累计成本与摊销成本。主要比较固定检索嵌入、Retriever、Reader、Judge、数据划分和随机种子，并同时报告价格相关费用与价格无关 Token 指标。

消融实验控制在能够回答核心机制的范围内，重点考察：移除 MemoryPrint、移除结构特征、用参数规模或通用榜单替代 MemoryPrint、把价格写入质量模型与外部解耦方案的差异，以及不同模型或模型家族留出条件下的表现。更复杂的不确定性估计、在线 Bandit 和多头质量建模暂不作为开题阶段的主方案，可在核心方法完成后作为扩展研究。

4.3 可行性分析

数据与评价具有可行性。LoCoMo、LongMemEval、HaluMem 和 MemoryAgentBench 等工作提供了长对话、知识更新、拒答、幻觉与增量交互等互补场景[17-20]。虽然片段级完整 Gold Fact 有限，但可通过独立探针、冻结参考抽取与严格匹配构造 Silver 标签，并通过抽样人工核验和多种标签构造消融评估其可靠性。

工程基础具有可行性。当前项目已经具备 LoCoMo 和 LongMemEval 数据标准化、主题分段、多档候选记忆生成、Qdrant 隔离存储、Token 与费用账本、检

索问答及评估等模块，并实现了固定三动作强化学习路由基线和数据划分审计。后续工作主要是在现有管线中补充 MemoryPrint、共享标量质量预测器与外部约束优化器，并将已有强化学习路由保留为比较基线。现有模块采用配置、运行清单、哈希和数据库账本记录实验身份，为可恢复执行和结果复核提供基础。

计算与组织上，候选记忆可以离线生成并复用，质量预测器规模相对较小，预算求解可以采用确定性算法。实验可分阶段推进，先验证片段—模型质量预测，再验证预算分配，最后开展端到端问答和跨数据集测试，降低一次性完成全部系统的风险。

4.4 风险、限制与备选方案

第一，Silver Fact 标签可能存在评估器偏差。拟通过固定评估协议、多构造方式对照、抽样人工检查及下游 QA 交叉验证降低单一评估器影响。第二，模型数量和家族有限会约束泛化结论，论文将把结论限定在所选模型范围，并采用留一模型或留一家族测试；若泛化不足，则将 MemoryPrint 降维或引入轻量目标域校准。第三，供应商价格和接口可能变化，因此所有费用均记录快照日期，并保留 Token 指标作为稳定参照。第四，持久写入可能丢失未来问题所需的细节，故需同时报告事实忠实度、拒答和证据支持，并与查询感知方法进行公平比较。第五，外部 API 费用和运行时间可能限制大规模实验，备选方案是先冻结小规模候选池完成方法验证，再逐步扩展模型和数据集。

5 进度安排

以下时间为根据当前开题时间拟定的工作计划，具体节点需结合培养环节和导师意见调整。

时间	主要任务	阶段成果
2026 年 9 月—10 月	补充文献调研，冻结研究问题、术语、数据划分和评价协议	文献矩阵、研究方案定稿、数据隔离清单
2026 年 11 月—12 月	完成数据标准化、主题分段复核和候选模型池确定	可复现数据与分段工件、候选模型配置

时间	主要任务	阶段成果
2027 年 1 月—3 月	构建并核验 MemoryPrint，生成片段—模型监督数据	模型能力表示、Silver 标签与质量审计报告
2027 年 4 月—5 月	训练共享质量预测器，完成训练集内验证	质量预测模型、误差分析和消融结果
2027 年 6 月—7 月	实现外部成本建模与预算约束优化，完成持久写入	预算分配模块、路由记忆库与成本账本
2027 年 8 月—9 月	开展路由基线、端到端对比和跨数据集验证	多预算质量—成本结果、泛化与生命周期分析
2027 年 10 月	汇总统计结果，完成风险和失败案例分析	图表、实验复核记录、论文核心结论边界
2027 年 11 月—12 月	完成论文初稿、修改、送审与答辩准备	学位论文、复现实验材料和答辩文稿

6 预期成果

- 一套面向长期记忆写入阶段的片段级模型路由方法及可复现实验流程。
- 一个价格无关的候选模型记忆能力表示和片段—模型质量预测器。
- 一个将质量预测、Token 成本和写入预算解耦的模型分配模块。
- 在多预算、多个候选模型和至少两个长期记忆数据集上的受控实验结果，包括事实质量、下游 QA、路由决策与成本指标。
- 一套一次写入、多次复用的生命周期成本分析及相应风险、限制和适用条件说明。
- 完整硕士学位论文，以及必要的配置、日志、账本和核心代码。上述成果均为计划目标，最终结论以正式实验和导师审核为准。

7 主要参考文献

- [1] Jizhan Fang, Xinle Deng, Haoming Xu, Ziyang Jiang, Yuqi Tang, Ziwen Xu, et al. LightMem: Lightweight and Efficient Memory-Augmented Generation. arXiv preprint arXiv:2510.18866, 2025. <https://doi.org/10.48550/arXiv.2510.18866>
- [2] Haozhen Zhang, Haodong Yue, Tao Feng, Quanyu Long, Jianzhu Bao, Bowen Jin, et al. Learning Query-Aware Budget-Tier Routing for Runtime Agent Memory. arXiv preprint arXiv:2602.06025, 2026. <https://doi.org/10.48550/arXiv.2602.06025>
- [3] Tao Feng, Fangxu Yu, Haozhen Zhang, Zhongjie Dai, Liangqi Yuan, Zijie Lei, et al. LLMRouter: Unified Infrastructure for Developing, Evaluating, and Deploying LLM Routers. arXiv preprint arXiv:2608.06867, 2026. <https://doi.org/10.48550/arXiv.2608.06867>
- [4] Isaac Ong, Amjad Almahairi, Vincent Wu, Wei-Lin Chiang, Tianhao Wu, Joseph E. Gonzalez, et al. RouteLLM: Learning to Route LLMs with Preference Data. arXiv preprint arXiv:2406.18665, 2024. <https://doi.org/10.48550/arXiv.2406.18665>
- [5] Wittawat Jitkrittum, Harikrishna Narasimhan, Ankit Singh Rawat, Jeevesh Juneja, Congchao Wang, Zifeng Wang, et al. Universal Model Routing for Efficient LLM Inference. arXiv preprint arXiv:2502.08773, 2025. <https://doi.org/10.48550/arXiv.2502.08773>
- [6] Qitian Jason Hu, Jacob Bieker, Xiuyu Li, Nan Jiang, Benjamin Keigwin, Gaurav Ranganath, et al. RouterBench: A Benchmark for Multi-LLM Routing System. arXiv preprint arXiv:2403.12031, 2024. <https://doi.org/10.48550/arXiv.2403.12031>
- [7] Lingjiao Chen, Matei Zaharia, James Zou. FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance. arXiv preprint arXiv:2305.05176, 2023. <https://doi.org/10.48550/arXiv.2305.05176>
- [8] Dujian Ding, Ankur Mallick, Chi Wang, Robert Sim, Subhabrata Mukherjee, Victor Ruhle, et al. Hybrid LLM: Cost-Efficient and Quality-Aware Query Routing. arXiv preprint arXiv:2404.14618, 2024. <https://doi.org/10.48550/arXiv.2404.14618>
- [9] Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, Deshraj Yadav. Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory. arXiv preprint arXiv:2504.19413, 2025. <https://doi.org/10.48550/arXiv.2504.19413>
- [10] Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, Yongfeng Zhang. A-MEM: Agentic Memory for LLM Agents. arXiv preprint arXiv:2502.12110, 2025. <https://doi.org/10.48550/arXiv.2502.12110>
- [11] Sikuan Yan, Xiufeng Yang, Zuchao Huang, Ercong Nie, Zifeng Ding, Zonggen Li, et al.

- Memory-R1: Enhancing Large Language Model Agents to Manage and Utilize Memories via Reinforcement Learning. arXiv preprint arXiv:2508.19828, 2025. <https://doi.org/10.48550/arXiv.2508.19828>
- [12] Jiaqi Liu, Yaofeng Su, Peng Xia, Siwei Han, Zeyu Zheng, Cihang Xie, et al. SimpleMem: Efficient Lifelong Memory for LLM Agents. arXiv preprint arXiv:2601.02553, 2026. <https://doi.org/10.48550/arXiv.2601.02553>
- [13] Yuxin Liao, Le Wu, Min Hou, Hao Liu, Han Wu, Zishu Wang. LeanMem: Simple and Efficient Long-Term Memory for LLM Agents. arXiv preprint arXiv:2608.03463, 2026. <https://doi.org/10.48550/arXiv.2608.03463>
- [14] Charles Packer, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G. Patil, Ion Stoica, et al. MemGPT: Towards LLMs as Operating Systems. arXiv preprint arXiv:2310.08560, 2023. <https://doi.org/10.48550/arXiv.2310.08560>
- [15] Wanjun Zhong, Lianghong Guo, Qiqi Gao, He Ye, Yanlin Wang. MemoryBank: Enhancing Large Language Models with Long-Term Memory. arXiv preprint arXiv:2305.10250, 2023. <https://doi.org/10.48550/arXiv.2305.10250>
- [16] Zhuoshi Pan, Qianhui Wu, Huiqiang Jiang, Menglin Xia, Xufang Luo, Jue Zhang, et al. LLMingua-2: Data Distillation for Efficient and Faithful Task-Agnostic Prompt Compression. arXiv preprint arXiv:2403.12968, 2024. <https://doi.org/10.48550/arXiv.2403.12968>
- [17] Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, Yuwei Fang. Evaluating Very Long-Term Conversational Memory of LLM Agents. arXiv preprint arXiv:2402.17753, 2024. <https://doi.org/10.48550/arXiv.2402.17753>
- [18] Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, Dong Yu. LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory. arXiv preprint arXiv:2410.10813, 2024. <https://doi.org/10.48550/arXiv.2410.10813>
- [19] Ding Chen, Simin Niu, Kehang Li, Peng Liu, Xiangping Zheng, Bo Tang, et al. HaluMem: Evaluating Hallucinations in Memory Systems of Agents. arXiv preprint arXiv:2511.03506, 2025. <https://doi.org/10.48550/arXiv.2511.03506>
- [20] Yuanzhe Hu, Yu Wang, Julian McAuley. Evaluating Memory in LLM Agents via Incremental Multi-Turn Interactions. arXiv preprint arXiv:2507.05257, 2025. <https://doi.org/10.48550/arXiv.2507.05257>

研究生签字

指导教师签字

院(系、所)领导签字

年 月 日